

LAPORAN TUGAS KELOMPOK 5
STATISTIKA DAN ANALITIKA DATA SIBER BISNIS (14823434)



Disusun oleh:

Andara Eka Valent_1482400023

Cagar Nalendra_148240068

Aliefa Gladies Oktavia_1482400073

Dosen Pengampu:

Bagus Hardiansyah, S.Kom., M.Si.

PRODI SISTEM DAN TEKNOLOGI INFORMASI
FAKULTAS TEKNOLOGI ELEKTRO DAN INFORMASI CERDAS
UNIVERSITAS 17 AGUSTUS 1945 SURABAYA
JUNI 2026

DAFTAR ISI

DAFTAR ISI.....	2
BAB I PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah.....	4
1.3 Tujuan Penelitian.....	5
1.4 Manfaat Penelitian.....	5
BAB II TINJAUAN PUSTAKA.....	6
2.1 Insiden Siber dan Anomali pada Sistem Layanan Bisnis Digital.....	6
2.2 Sampling Distribution.....	6
2.3 Confidence Interval.....	6
2.4 Dataset Penelitian.....	7
BAB III METODE PENELITIAN.....	8
3.1 Jenis Data dan Sumber Data.....	8
3.2 Variabel Penelitian.....	8
3.3 Alat dan Tools.....	8
3.4 Tahapan Analisis.....	8
BAB IV HASIL DAN PEMBAHASAN.....	9
4.1 Hasil Eksplorasi Data (EDA).....	9
4.2 Hasil Simulasi Sampling Distribution.....	11
4.3 Hasil Perhitungan Confidence Interval.....	11
BAB V KESIMPULAN DAN SARAN.....	13
5.1 Kesimpulan.....	13
5.2 Saran.....	13
DAFTAR PUSTAKA.....	14

BAB I PENDAHULUAN

1.1 Latar Belakang

Di era digital saat ini, insiden keamanan siber merupakan ancaman yang terus meningkat seiring dengan berkembangnya sistem layanan bisnis digital. Volume log yang dihasilkan oleh sistem-sistem tersebut terus bertumbuh secara eksponensial, sehingga deteksi anomali secara manual menjadi semakin tidak feasible. Penelitian oleh Alaca, Çelik, dan Goel (2023) menunjukkan bahwa data log bersifat heterogen dan memerlukan pendekatan sistematis untuk dapat mengidentifikasi pola anomali secara efektif. Kecepatan suatu organisasi dalam merespons insiden siber menjadi indikator penting dalam mengukur efektivitas sistem keamanan operasionalnya. Waktu respons yang cepat dapat meminimalkan dampak kerugian, sementara waktu respons yang lambat dapat memperbesar risiko terhadap kelangsungan layanan bisnis.

Untuk memahami karakteristik waktu respons insiden siber, diperlukan pendekatan statistik yang dapat menggambarkan pola data secara objektif. Konsep sampling distribution dan confidence interval merupakan dua pendekatan statistik inferensial yang dapat digunakan untuk mengestimasi parameter populasi berdasarkan data sampel. Namun demikian, perlu diwaspadai bahwa interpretasi hasil simulasi sampling distribution dapat menimbulkan kesalahpahaman konseptual, sebagaimana diulas oleh Watkins, Bargagliotti, dan Franklin (2014), yang menekankan pentingnya pemahaman yang tepat mengenai properti mean dan standar deviasi dari sampling distribution.

Laporan ini membahas analisis statistik terhadap data Logging & Monitoring Anomalies Dataset untuk mengkaji distribusi waktu respons insiden siber pada sistem layanan bisnis digital.

1.2 Rumusan Masalah

1. Bagaimana karakteristik distribusi data waktu respons (Response_Time_ms) pada sistem layanan bisnis digital?
2. Bagaimana bentuk sampling distribution dari rata-rata waktu respons insiden siber, dan apakah pola yang teramati dari simulasi mencerminkan properti teoritis yang benar?

3. Berapa estimasi confidence interval untuk rata-rata waktu respons insiden siber, dan apakah estimasi tersebut valid?

1.3 Tujuan Penelitian

1. Menganalisis karakteristik distribusi data waktu respons insiden siber (Response_Time_ms) pada sistem layanan bisnis digital.
2. Membuktikan konsep Central Limit Theorem (CLT) melalui simulasi sampling distribution, dengan memperhatikan potensi misleading interpretation sebagaimana diidentifikasi oleh Watkins et al. (2014).
3. Menghitung estimasi confidence interval untuk rata-rata waktu respons insiden siber pada tingkat kepercayaan 95%.

1.4 Manfaat Penelitian

1. Bagi penulis: menambah pemahaman dan keterampilan dalam penerapan konsep statistik inferensial (sampling distribution dan confidence interval) pada data dunia nyata, termasuk kewaspadaan terhadap interpretasi yang keliru.
2. Bagi pembaca/pihak terkait: memberikan gambaran mengenai karakteristik waktu respons insiden siber yang dapat dijadikan acuan dalam mengevaluasi efektivitas sistem keamanan operasional.
3. Bagi pengembangan ilmu: menjadi referensi penerapan metode statistik dalam konteks analisis keamanan siber pada sistem bisnis digital.

BAB II TINJAUAN PUSTAKA

2.1 Insiden Siber dan Anomali pada Sistem Layanan Bisnis Digital

Insiden siber adalah segala bentuk gangguan atau ancaman yang terjadi pada sistem informasi, termasuk serangan jaringan, kebocoran data, maupun anomali pada aktivitas sistem. Waktu respons terhadap insiden (response time) merupakan salah satu metrik utama dalam mengukur kesiapan dan efektivitas tim keamanan dalam menangani gangguan tersebut. Data log yang dihasilkan oleh sistem digital mencatat peristiwa-peristiwa ini secara kontinyu, menghasilkan volume data yang sangat besar dan heterogen.

Alaca et al. (2023) mengklasifikasikan anomali dalam log data ke dalam tiga kategori utama: point anomaly (data yang menyimpang signifikan dari rata-rata distribusi), contextual anomaly (perilaku abnormal yang terbatas pada konteks tertentu), dan collective anomaly (perilaku abnormal dari sekumpulan data secara kolektif terhadap keseluruhan dataset). Pemahaman terhadap jenis-jenis anomali ini relevan dalam menginterpretasikan variasi pada data waktu respons yang dianalisis dalam laporan ini.

2.2 Sampling Distribution

Sampling distribution adalah distribusi probabilitas dari suatu statistik (misalnya rata-rata) yang dihitung dari sejumlah sampel acak berukuran tertentu yang diambil berulang kali dari suatu populasi. Berdasarkan Central Limit Theorem (CLT), apabila ukuran sampel cukup besar, maka distribusi rata-rata sampel akan mendekati distribusi normal, terlepas dari bentuk distribusi populasi aslinya.

Satu aspek krusial yang sering disalahpahami adalah bahwa mean dari sampling distribution selalu sama persis dengan mean populasi untuk semua ukuran sampel, bukan hanya untuk sampel berukuran besar. Watkins et al. (2014) secara khusus memperingatkan bahwa simulasi sampling distribution dapat memperkuat kesalahpahaman ini: ketika ukuran sampel n meningkat, mean dari simulated SDM yang dibangun dari N sampel acak cenderung mendekati mean populasi—bukan karena properti teoritis berubah, melainkan karena variansi estimator tersebut berbanding terbalik dengan $n \times N$. Dengan demikian, pola yang teramati merupakan artefak simulasi, bukan bukti bahwa properti mean SDM bergantung pada ukuran sampel.

2.3 Confidence Interval

Confidence interval (interval kepercayaan) adalah rentang nilai yang digunakan untuk mengestimasi parameter populasi (misalnya rata-rata) berdasarkan data sampel, dengan tingkat kepercayaan tertentu (umumnya 95%). Interval ini dihitung menggunakan rumus:

$$CI = \bar{x} \pm (t_{kritis} \times SE)$$

di mana $\bar{x}$ adalah rata-rata sampel, t_{kritis} adalah nilai kritis dari distribusi t pada derajat kebebasan ($n-1$), dan SE adalah standard error (standar deviasi sampel dibagi akar dari ukuran sampel). Perlu dipahami bahwa interpretasi confidence interval yang benar adalah: jika prosedur ini diulang berkali-kali, 95% dari interval yang dihasilkan akan mencakup nilai parameter populasi yang sebenarnya.

2.4 Dataset Penelitian

Data yang digunakan dalam penelitian ini adalah Logging & Monitoring Anomalies Dataset yang diperoleh dari platform Kaggle. Dataset ini berisi 100.000 baris dan 31 kolom data yang merepresentasikan log insiden siber pada sistem operasional, termasuk waktu respons (Response_Time_ms), tingkat keparahan (Severity), jenis anomali (Anomaly_Type), dan berbagai metrik operasional lainnya.

BAB III METODE PENELITIAN

3.1 Jenis Data dan Sumber Data

Penelitian ini menggunakan data sekunder berupa Logging & Monitoring Anomalies Dataset yang bersumber dari Kaggle, terdiri dari 100.000 baris data insiden siber yang tercatat pada periode 1 Januari – 11 Maret 2025.

3.2 Variabel Penelitian

Variabel utama yang dianalisis adalah Response_Time_ms (waktu respons sistem terhadap insiden, dalam satuan milidetik). Variabel pendukung yang digunakan untuk analisis tambahan adalah Severity (tingkat keparahan insiden) dan Anomaly_Type (jenis anomali).

3.3 Alat dan Tools

Analisis dilakukan menggunakan bahasa pemrograman Python pada platform Google Colaboratory, dengan pustaka pandas untuk pengolahan data, matplotlib dan seaborn untuk visualisasi, serta scipy.stats untuk perhitungan statistik inferensial.

3.4 Tahapan Analisis


1. Eksplorasi Data (EDA): pengecekan struktur data, missing value, duplikasi data, statistik deskriptif, visualisasi distribusi (histogram dan boxplot), analisis perbandingan antar kategori, serta deteksi outlier menggunakan metode IQR.
2. Simulasi Sampling Distribution: pengambilan 1.000 sampel acak (masing-masing berukuran $n=50$) dari data populasi, kemudian menghitung rata-rata setiap sampel untuk membentuk distribusi rata-rata sampel (sampling distribution). Interpretasi hasil simulasi dilakukan dengan memperhatikan peringatan Watkins et al. (2014) mengenai potensi bias persepsi akibat artefak simulasi.
3. Perhitungan Confidence Interval: pengambilan satu sampel acak berukuran $n=100$ untuk mensimulasikan skenario di mana hanya tersedia data sampel, kemudian dihitung confidence interval 95% menggunakan distribusi t , serta divalidasi menggunakan metode bootstrap sebagai pembanding.

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil Eksplorasi Data (EDA)

Dataset terdiri dari 100.000 baris dan 31 kolom, dengan seluruh kolom memiliki kelengkapan data 100% (tidak ditemukan missing value maupun data duplikat).

Variabel `Response_Time_ms` memiliki rata-rata 5.009,35 ms dan standar deviasi 2.880,76 ms, dengan rentang nilai 10–9.999 ms. Nilai skewness sebesar $-0,008$ menunjukkan distribusi data yang hampir simetris, sedangkan nilai kurtosis $-1,196$ mengindikasikan bentuk distribusi yang lebih datar (platykurtic) dibandingkan distribusi normal. Visualisasi histogram pada Gambar 1 menunjukkan distribusi yang relatif seragam (uniform) di sepanjang rentang nilai, tanpa adanya nilai yang dominan menumpuk pada titik tertentu. Boxplot pada gambar yang sama memperlihatkan tidak adanya outlier yang signifikan.



Gambar 1. Histogram dan Boxplot distribusi `Response_Time_ms` ($n = 100.000$)


Pengecekan outlier menggunakan metode IQR menghasilkan batas bawah $-4.963,5$ ms dan batas atas $14.976,5$ ms, dengan hasil 0 outlier dari 100.000 baris data (0,00%). Hal ini konsisten dengan bentuk distribusi uniform yang tidak memiliki ekor ekstrem.

Hasil breakdown berdasarkan kategori Severity disajikan pada Tabel 1. Rata-rata waktu respons relatif konsisten di semua tingkat keparahan, dengan selisih kurang dari 1%. Visualisasi distribusi per kategori Severity ditampilkan pada Gambar 2.

Tabel 4.1 Rata-rata Response Time per Kategori Severity

Severity	Mean (ms)	Std (ms)	Count
Low	5.002,18	2.900,00	24.913
Medium	5.002,39	2.882,58	25.018


High	5.007,39	2.877,31	24.922
Critical	5.025,33	2.863,29	25.147



Gambar 2. Distribusi Response Time per tingkat Severity

Temuan serupa ditemukan pada kategori *Anomaly_Type*, dengan rata-rata berkisar antara 4.974,10 ms (Database) hingga 5.045,31 ms (Network), selisih kurang dari 1,5%. Hal ini mengindikasikan bahwa baik tingkat keparahan maupun jenis anomali tidak memberikan pengaruh signifikan terhadap cepat atau lambatnya waktu respons sistem. Temuan ini relevan dengan konteks pada Alaca et al. (2023), yang menyatakan bahwa anomali dalam log data dapat bersifat point anomaly namun tidak selalu berdampak pada variasi waktu respons secara keseluruhan.

Visualisasi tren jumlah insiden harian pada Gambar 3 menunjukkan jumlah yang relatif stabil pada kisaran 1.400–1.450 insiden per hari sepanjang periode pengamatan (1 Januari–11 Maret 2025).




Gambar 3. Jumlah insiden siber per hari selama periode pengamatan

4.2 Hasil Simulasi Sampling Distribution

Simulasi dengan mengambil 1.000 sampel acak berukuran $n=50$ dari populasi menghasilkan rata-rata dari seluruh sample means sebesar 5.006,00 ms, mendekati rata-rata populasi sebenarnya (5.009,35 ms). Standar deviasi empiris dari sampling distribution (406,73 ms) juga sangat mendekati nilai standard error teoritis (407,40 ms), yang dihitung dari standar deviasi populasi dibagi akar ukuran sampel.

Histogram dari sampling distribution ditampilkan pada Gambar 4. Secara visual, distribusi tersebut menyerupai kurva normal, meskipun data populasi aslinya berdistribusi uniform. Temuan ini membuktikan secara empiris berlakunya Central Limit Theorem.



Gambar 4. Sampling distribution rata-rata Response_Time_ms (1.000 sampel, $n = 50$)


Namun demikian, penting untuk mencermati interpretasi pola ini dengan hati-hati. Sebagaimana diperingatkan oleh Watkins et al. (2014), ketika simulasi sampling distribution dibangun dengan ukuran sampel yang bervariasi (n semakin besar), mean dari simulated SDM akan terlihat semakin mendekati mean populasi. Pola ini bukan merupakan implikasi dari properti teoritis baru, melainkan merupakan artefak statistik: variansi dari mean simulated SDM sebesar $\sigma^2/(n \times N)$ menurun seiring meningkatnya n maupun N . Secara teoritis, mean SDM tetap sama persis dengan mean populasi untuk semua ukuran sampel n , bukan hanya untuk n yang besar. Kesadaran terhadap potensi misleading ini penting agar tidak menimbulkan kesimpulan yang keliru.

4.3 Hasil Perhitungan Confidence Interval

Pada simulasi pengambilan satu sampel acak berukuran $n=100$, diperoleh rata-rata sampel sebesar 5.195,46 ms dengan standar deviasi 2.776,91 ms. Berdasarkan nilai standard error

(277,69 ms) dan nilai kritis distribusi t pada derajat kebebasan 99 dengan tingkat kepercayaan 95% ($t = 1,984$), diperoleh margin of error sebesar 551,00 ms.

Dengan demikian, confidence interval 95% untuk rata-rata waktu respons adalah [4.644,46 ms; 5.746,46 ms]. Rata-rata populasi sebenarnya (5.009,35 ms) berada di dalam rentang tersebut, yang membuktikan validitas estimasi confidence interval yang dihasilkan. Visualisasi confidence interval disajikan pada Gambar 5.



Gambar 5. Visualisasi 95% Confidence Interval untuk rata-rata Response_Time_ms

Sebagai pembandingan, perhitungan confidence interval menggunakan metode bootstrap (5.000 kali resampling) menghasilkan rentang [4.658,93 ms; 5.744,80 ms], yang relatif konsisten dengan hasil metode distribusi t. Perbandingan kedua metode disajikan pada Tabel 2.

Tabel 2. Perbandingan hasil Confidence Interval 95%

Metode	Batas Bawah (ms)	Batas Atas (ms)
Distribusi t (teoritis)	4.644,46	5.746,46
Bootstrap (5.000 resampling)	4.658,93	5.744,80

Kesesuaian antara dua metode ini memperkuat keandalan hasil estimasi confidence interval pada penelitian ini. Perbedaan yang kecil antara keduanya juga mengindikasikan bahwa asumsi normalitas yang digunakan dalam metode distribusi t terpenuhi dengan baik, konsisten dengan hasil simulasi sampling distribution yang menunjukkan bentuk mendekati normal.

BAB V KESIMPULAN DAN SARAN

5.1 Kesimpulan

1. Variabel `Response_Time_ms` pada sistem layanan bisnis digital memiliki distribusi yang relatif simetris dan seragam (uniform), dengan rata-rata 5.009,35 ms dan tidak ditemukan adanya data outlier.
2. Tingkat keparahan insiden (`Severity`) maupun jenis anomali (`Anomaly_Type`) tidak menunjukkan pengaruh yang signifikan terhadap waktu respons sistem, dengan selisih rata-rata antar kategori kurang dari 1,5%.
3. Simulasi `sampling distribution` berhasil membuktikan berlakunya Central Limit Theorem, di mana distribusi rata-rata sampel mendekati distribusi normal meskipun populasi aslinya berdistribusi uniform. Namun, interpretasi pola visual simulasi perlu dilakukan secara kritis: pola kedekatan mean simulated SDM terhadap mean populasi pada n yang lebih besar merupakan artefak statistik, bukan perubahan properti teoritis SDM (Watkins et al., 2014).
4. Estimasi confidence interval 95% untuk rata-rata waktu respons, yaitu [4.644,46 ms; 5.746,46 ms], terbukti valid karena berhasil mencakup nilai rata-rata populasi sebenarnya, dan didukung oleh hasil yang konsisten dari metode bootstrap.

5.2 Saran

1. Penelitian selanjutnya dapat menggunakan data insiden siber riil dari organisasi tertentu untuk memperoleh gambaran yang lebih representatif terhadap kondisi sesungguhnya.
2. Perlu dilakukan analisis lanjutan dengan mempertimbangkan variabel lain seperti `Alert_Method` atau `Service_Type` untuk mengidentifikasi faktor yang lebih berpengaruh terhadap waktu respons.
3. Pengembangan sistem deteksi anomali berbasis machine learning, seperti pendekatan GLSTM yang diusulkan oleh Alaca et al. (2023), dapat diujicoba sebagai langkah lanjutan untuk menganalisis pola anomali log siber secara lebih mendalam dan akurat.
4. Dalam pemanfaatan simulasi `sampling distribution` untuk keperluan analisis maupun pembelajaran, penting untuk selalu mengkomunikasikan potensi misleading interpretation kepada pembaca atau audiens, sesuai rekomendasi Watkins et al. (2014).

DAFTAR PUSTAKA

Alaca, Y., Celik, Y., & Goel, S. (2023). Anomaly detection in cyber security with graph-based LSTM in log analysis. *Chaos Theory and Applications*, 5(3), 188-197.

Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical statistics for data scientists: 50+ essential concepts using R and Python*. O'Reilly Media.

Kaggle. (2025). Logging & Monitoring Anomalies Dataset. Diakses dari <https://www.kaggle.com>

Watkins, A. E., Bargagliotti, A., & Franklin, C. (2014). Simulation of the sampling distribution of the mean can mislead. *Journal of Statistics Education*, 22(3).